

Data Frames II

Santiago Lozano

21 de marzo de 2020

Usar `order()` y `!duplicated()` para eliminar pseudoreplicación

En un ejemplo más complicado quisieramos extraer una observación de cada tipo de vegetación, y que si es así que extraiga el de worm density mayor. Hay 2 pasos par hacer, el primero es ordenar las filas y el segundo es seleccionar los no duplicados, así

```
setwd("C:/Users/santiago/Documents/Progrmación en R/2020-I/PR08-Data Frames")
worms <- read.table("worms.txt",header = T,dec = ".")
attach(worms)
```

```
new <- worms[rev(order(Worm.density)),]
new[!duplicated(new$Vegetation),]
```

##	Field.Name	Area	Slope	Vegetation	Soil.pH	Damp	Worm.density
## 9	The.Orchard	1.9	0	Orchard	5.7	FALSE	9
## 16	Water.Meadow	3.9	0	Meadow	4.9	TRUE	8
## 11	Garden.Wood	2.9	10	Scrub	5.2	FALSE	8
## 10	Rookery.Slope	1.5	4	Grassland	5.0	TRUE	7
## 2	Silwood.Bottom	5.1	2	Arable	5.2	FALSE	7

Ordenamiento complejo

Existen ocasiones em la que queremos order varias variables pero ordenarlas en sentidos opuestos

```
worms[order(Vegetation,-Worm.density),]
```

##	Field.Name	Area	Slope	Vegetation	Soil.pH	Damp	Worm.density
## 2	Silwood.Bottom	5.1	2	Arable	5.2	FALSE	7
## 18	Pound.Hill	4.4	2	Arable	4.5	FALSE	5
## 8	Ashurst	2.1	0	Arable	4.8	FALSE	4
## 10	Rookery.Slope	1.5	4	Grassland	5.0	TRUE	7
## 1	Nashs.Field	3.6	11	Grassland	4.1	FALSE	4
## 7	Church.Field	3.5	3	Grassland	4.2	FALSE	3
## 3	Nursery.Field	2.8	3	Grassland	4.3	FALSE	2
## 6	Oak.Mead	3.1	2	Grassland	3.9	FALSE	2
## 13	South.Gravel	3.7	2	Grassland	4.0	FALSE	2
## 12	North.Gravel	3.3	1	Grassland	4.1	FALSE	1
## 19	Gravel.Pit	2.9	1	Grassland	3.5	FALSE	1
## 14	Observatory.Ridge	1.8	6	Grassland	3.8	FALSE	0
## 16	Water.Meadow	3.9	0	Meadow	4.9	TRUE	8
## 15	Pond.Field	4.1	0	Meadow	5.0	TRUE	6
## 4	Rush.Meadow	2.4	5	Meadow	4.9	TRUE	5
## 9	The.Orchard	1.9	0	Orchard	5.7	FALSE	9
## 11	Garden.Wood	2.9	10	Scrub	5.2	FALSE	8
## 5	Gunness.Thicket	3.8	0	Scrub	4.2	FALSE	6
## 17	Cheapside	2.2	8	Scrub	4.7	TRUE	4
## 20	Farm.Wood	0.8	10	Scrub	5.1	TRUE	3

Aquí Vegetation se orden alfabético, pero worm density se ordenó de mayor a menor

Para ordenar de manera contraria al alfabeto podemos usar la función rank()

```
worms[order(-rank(Vegetation),-Worm.density),]
```

```
##      Field.Name Area Slope Vegetation Soil.pH Damp Worm.density
## 11  Garden.Wood  2.9   10    Scrub    5.2 FALSE         8
##  5  Gunness.Thicket 3.8    0    Scrub    4.2 FALSE         6
## 17   Cheapside  2.2    8    Scrub    4.7  TRUE         4
## 20   Farm.Wood  0.8   10    Scrub    5.1  TRUE         3
##  9   The.Orchard 1.9    0   Orchard    5.7 FALSE         9
## 16  Water.Meadow 3.9    0   Meadow    4.9  TRUE         8
## 15   Pond.Field 4.1    0   Meadow    5.0  TRUE         6
##  4   Rush.Meadow 2.4    5   Meadow    4.9  TRUE         5
## 10  Rookery.Slope 1.5    4 Grassland    5.0  TRUE         7
##  1   Nashs.Field 3.6   11 Grassland    4.1 FALSE         4
##  7   Church.Field 3.5    3 Grassland    4.2 FALSE         3
##  3   Nursery.Field 2.8    3 Grassland    4.3 FALSE         2
##  6    Oak.Mead  3.1    2 Grassland    3.9 FALSE         2
## 13   South.Gravel 3.7    2 Grassland    4.0 FALSE         2
## 12   North.Gravel 3.3    1 Grassland    4.1 FALSE         1
## 19    Gravel.Pit 2.9    1 Grassland    3.5 FALSE         1
## 14 Observatory.Ridge 1.8    6 Grassland    3.8 FALSE         0
##  2   Silwood.Bottom 5.1    2   Arable    5.2 FALSE         7
## 18    Pound.Hill 4.4    2   Arable    4.5 FALSE         5
##  8    Ashurst  2.1    0   Arable    4.8 FALSE         4
```

Una forma menos probable de ordenar será seleccionando columna sobre operadores lógico. Suponga que por alguna razón usted quiere seleccionar las columnas que contienen el carácter “S”, así

```
names(worms)
```

```
## [1] "Field.Name" "Area"      "Slope"     "Vegetation"
## [5] "Soil.pH"    "Damp"      "Worm.density"
```

```
grep("S",names(worms))
```

```
## [1] 3 5
```

de esta manera

```
worms[,grep("S",names(worms))]
```

```
##      Slope Soil.pH
## 1      11    4.1
## 2       2    5.2
## 3       3    4.3
## 4       5    4.9
## 5       0    4.2
## 6       2    3.9
## 7       3    4.2
## 8       0    4.8
## 9       0    5.7
## 10      4    5.0
## 11     10    5.2
## 12      1    4.1
## 13     2    4.0
```

```
## 14      6      3.8
## 15      0      5.0
## 16      0      4.9
## 17      8      4.7
## 18      2      4.5
## 19      1      3.5
## 20     10      5.1
```

Un Dataframe con nombres de filas en vez de número de fila

Podemos suprimir la creación de número de filas, ubicando su propio nombre de cada fila alterando la sintaxis de `read.table`

```
worms2 <- read.table("worms.txt",header = T,dec = ".",row.names = 1)
worms2
```

```
##           Area Slope Vegetation Soil.pH  Damp Worm.density
## Nashs.Field    3.6   11  Grassland   4.1 FALSE           4
## Silwood.Bottom  5.1    2   Arable   5.2 FALSE           7
## Nursery.Field   2.8    3  Grassland   4.3 FALSE           2
## Rush.Meadow     2.4    5   Meadow   4.9  TRUE           5
## Gunness.Thicket 3.8    0    Scrub   4.2 FALSE           6
## Oak.Mead        3.1    2  Grassland   3.9 FALSE           2
## Church.Field    3.5    3  Grassland   4.2 FALSE           3
## Ashurst         2.1    0   Arable   4.8 FALSE           4
## The.Orchard     1.9    0  Orchard   5.7 FALSE           9
## Rookery.Slope   1.5    4  Grassland   5.0  TRUE           7
## Garden.Wood     2.9   10    Scrub   5.2 FALSE           8
## North.Gravel    3.3    1  Grassland   4.1 FALSE           1
## South.Gravel    3.7    2  Grassland   4.0 FALSE           2
## Observatory.Ridge 1.8    6  Grassland   3.8 FALSE           0
## Pond.Field      4.1    0   Meadow   5.0  TRUE           6
## Water.Meadow    3.9    0   Meadow   4.9  TRUE           8
## Cheapside       2.2    8    Scrub   4.7  TRUE           4
## Pound.Hill      4.4    2   Arable   4.5 FALSE           5
## Gravel.Pit      2.9    1  Grassland   3.5 FALSE           1
## Farm.Wood       0.8   10    Scrub   5.1  TRUE           3
```

Crear un dataframe a partir de otro tipo de objeto

Sabemos que podemos usar la función `table()` para contar los elementos de un vector

```
y <- rpois(1500,1.5)
table(y)
```

```
## y
##  0  1  2  3  4  5  6  7
## 340 465 405 192  70  22  4  2
```

Y Podemos este simple conteo convertirlo en un dataframe

```
short<-as.data.frame(table(y))
short
```

```
##   y Freq
```

```
index<-rep(1:8,short$Freq)
index
```

4

```
## [1463] 5 5 5 5 5 5 5 5 5 5 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 7 7  
## [1497] 7 7 8 8
```